

FEMS 적용을 위한 LSTM 기반의 식품공장 에너지 소비 예측 모델의 최적화

이형아 · 김동주 · 조우진 · 구재회[†]

고등기술연구원 에너지환경IT융합그룹, 17180 경기도 용인시 처인구 백암면 고안로 51번길 175-28

Optimization of Energy Consumption Prediction Model of Food Factory based on LSTM for Application to FEMS

Hyung-Ah Lee · Dong-Ju Kim · Woo-Jin Cho · Jae-Hoi Gu[†]

Energy Environment IT Convergence Group, Institute for Advanced Engineering 175-28

Goan-ro 51 beon-gil, Beagam-myeon, Cheoin-gu, Yongin-si, Gyeonggi-do, 17180, KOREA

ABSTRACT : There is an increasing need for reducing greenhouse gas emissions and improving the efficiency of energy consumption. In particular, energy consumption in the domestic industrial sector accounts for a large portion of the total energy consumption and is on a steady increase; therefore, it is required to prepare measures to increase the efficiency of energy consumption. One of the measures can be FEMS, which has functions such as real-time monitoring of energy use, energy consumption analysis, and control of various facilities, is attracting attention. Prediction of energy consumption among the various functions is an important first step in properly designing energy supplies and factory operations. In this paper, a study on energy consumption prediction was conducted for the purpose of application to FEMS. Machine learning technique was used to obtain predicted values by training the predictive model using available data, and LSTM algorithm was applied. To select a model suitable for the target food factory, the validity of the prediction model according to the combination of hyper parameters and variables was analyzed with CvRMSE and R^2 . By applying the optimal combination, the average error rate and accuracy of the prediction were confirmed through comparison between the predicted and measured values.

Key words : FEMS, Machine Learning, LSTM, Energy Prediction, Optimization of Prediction Model

[†]Corresponding author(Jae-Hoi Gu) : E-mail: jaehoi@iae.re.kr Tel: 031-330-7870
Received: March 14, 2023; Revised: April 23, 2023; Accepted: April 24, 2023

1. 서론

다양한 부문에서 에너지 소비 절감을 위해 기존의 수동적 에너지 관리 방식에서 나아가 능동적 에너지 관리 방식을 채택하고 있으며, 이러한 측면에서 다양한 ICT(Information & Communication Technology) 기술이 적용되어 실시간으로 에너지 소비의 모니터링과 제어가 가능한 에너지관리시스템(Energy Management System, EMS)에 대한 관심이 증대되고 있다[1]. 그 중 공장에 적용되는 EMS인 공장에너지관리시스템(Factory Energy Management System, 이하 FEMS)은 공장의 에너지 소비를 통합적으로 모니터링하고 수집된 대용량의 에너지 데이터를 분석하며, 생산 휴지시간에 에너지를 소비하는 설비 및 유틸리티를 확인하고 최적 제어를 가능하게 하여 국내 산업부문의 에너지 소비 절감 기술로서 주목받고 있다.

2020년에 발표된 산업통상자원부의 에너지 총조사 결과에 의하면 국내 산업부문의 에너지 소비는 2016년에서 2019년 사이 연평균 1.7% 증가했으며, 2020년 기준 전체 에너지 소비의 60% 이상을 차지하는 막중한 비중을 보이고 있다[2]. 이에 정부는 제3차 에너지기본계획에서 2030년까지 산업부문의 온실가스 배출을 BAU* 대비 8.1%p 감축해야 하며, 10만TOE* 이상의 에너지 다소비 업체의 경우 2025년부터 FEMS의 설치를 의무화함을 언급하고 있다. 또한 10만 TOE 미만의 중소·중견기업의 경우, 스마트공장 과 연계해 FEMS 보급 지원을 확대하여 2040년까지 신규 3,000개 이상을 지원하는 것을 목표로 두고 있으며, FEMS에 대한 연구개발에 박차를 가하고 있다[3,4].

반면 최근 방대한 데이터에 대한 처리와 분석에 대한 요구로 빅데이터 분석 및 머신러닝 기반의 예측 연구가 활발히 진행되고 있으며, 여러 유형의 건물을 대상으로 에너지 소비 현황 분석

과 수요 예측을 통한 에너지 효율화에도 적용되고 있다. 이는 에너지 수요와 공급의 균형을 맞추고 불필요한 에너지 낭비를 줄여 환경문제를 해결하고 제반 비용을 줄이는 방안으로서 의의가 있다.

Miguel Martinez Comesaña[5]는 MLP(Multi-Layered Perceptron) 및 LSTM(Long Short Term Memory) neural networks를 사용해 북 스페인의 공공 도서관 건물을 대상으로 열 관성(thermal inertia)에 대해 연구하였다. 모델에 도입된 시차수에 따른 예측 오차와 평균 제곱근 편차 변동계수(Coefficient of Variation of Root Mean Squared Error, CvRMSE)를 비교 분석하였다. 연구 결과 열 지연(thermal lag)을 고려한 모델의 정확도가 높았으며, 열 수요에 대해 15% 미만의 오류, 실내 온도에 대해 2% 미만의 오류를 보였다.

Chanuk Lee[6]는 주거용 건물을 대상으로 ANN(Artificial Neural Network)을 활용해 난방 에너지 사용량의 예측에 대한 연구를 수행하였다. 다양한 입력 변수 조합을 사용해 ANN 모델을 통한 에너지 예측값의 결과를 비교 분석한 결과, 최상의 경우 CvRMSE 값이 3.0%, 평균적으로 7.3%, 최악의 경우 38.2%의 성능을 확인하였다.

QUAN JUNLONG[7]은 결측치가 포함된 실내 환경 데이터 및 에너지 소비 데이터를 활용해 사무실 건물의 에너지 데이터를 예측하는 연구를 하였다. 적은 양의 데이터로도 충분한 학습 데이터를 생성시킬 수 있는 VLSW(Variable-Length Sliding Window) 알고리즘과 일반 슬라이딩 알고리즘을 활용하여 결측치를 보간하고, SSIM(Sequence-to-Sequence Imputation Model) 모델과 LSTM 모델을 사용해 CvRMSE 값으로서 예측 정확도를 비교하였다. 연구 결과, SSIM 모델을 적용시킨 경우 미래의 3시간 예측의 CvRMSE 값은 23.76%, 6시간 예측에 있어서는 29.35%이었으며, LSTM 모델을 적용시킨 경우 3시간 예측의 CvRMSE 값은 39.54%, 6시간 예측에 있어서는 42.26%로, SSIM 모델을 적용하여 3시간 뒤의 건

물 에너지 소비 예측을 하는 경우에 예측 정확도가 가장 높음을 확인하였다.

양윤영[8]은 헬스케어 건물을 대상으로 MLR(Multiple Linear Regression), SVM(Support Vector Machine), ANN 기반의 예측 모델을 MATLAB(Matrix Laboratory)과 R프로그래밍을 통해 전력 사용량을 예측하였다. 예측 모델 성능의 비교 분석 결과, ANN 모델이 평균 제곱근 오차(Root Mean Square Error, RMSE)의 평균값 153.2로 가장 좋은 성능을 보였다.

최종석[9]은 LSTM과 RNN(Recurrent Neural Network)을 활용해 매장 건물의 전력 부하를 예측했다. LSTM의 경우 평균 오차 범위 값이 약 0.26, 30회의 오차 평균치가 0.29로 낮게 확인되어, 클러스터화된 전력 데이터의 학습 및 예측에 LSTM 알고리즘 사용이 적합함을 확인하였다.

선행연구 고찰 결과 주거용 건물, 사무실 건물, 상업 건물 등 다양한 유형의 건물을 대상으로 머신러닝 알고리즘 기반의 에너지 분석 및 예측 연구가 활발히 진행되고 있음을 확인할 수 있다. 하지만 공장, 특히 식품공장에 대해서는 연구가 미흡한 것으로 확인되었다. 건물 유형별로 에너지 사용에 영향을 미치는 주 요소, 건물 운영 특성, 재실자의 건물 사용 특성 등에 차이가 있고, 이러한 요소들은 건물의 에너지 소비 특성에 영향을 준다. 이는 에너지 분석 및 예측에 필요한 데이터가 건물 유형별로 상이함을 의미한다. 식품공장의 경우 에너지 사용이 제품 생산량의 영향을 많이 받으며, 식품의 가열, 급기, 살균 등의 공정 과정과 원재료 및 제품의 보관 과정에서의 에너지 소비 비중이 크다는 점, 그리고 주말 등의 비운영일이 있으며 비운영일에도 식품의 부패 방지 및 신선 유지를 위한 에너지 사용이 필요하다는 점 등에서 다른 유형의 건물과 차이가 있다[10]. 특정 유형의 건물 에너지 효율화를 위해 에너지 분석 및 예측에 대한 연구가 선행되어야 하며, 연구 자료의 축적을 통해 건물 유형별 에너지 분석 및 예측을 위해 필요한 데이터의 유형과 범주를 정리할 수 있다.

또한 선행연구에서는 예측 모델의 최적화 연

구에 있어 대체로 변수 조합 도출 과정만을 다루거나 파라미터 튜닝 과정만을 다루고 있음을 확인하였다. 예측 모델의 고도화를 위해서는 변수와 하이퍼파라미터에 대한 연구가 병행되어야 하며, 모델 최적화를 위한 일련의 과정을 다룸으로써 머신러닝 기반 에너지 분석 및 예측의 활성화에 기여할 수 있다.

이러한 배경 하에 본 연구에서는 식품공장을 대상으로 머신러닝 알고리즘 기반의 에너지 사용량 예측에 대해 고찰하였다. 에너지 사용량 예측을 위해 식품공장의 일 단위(daily) 데이터를 활용하기 때문에 머신러닝 알고리즘 중 시계열 데이터 예측에 특화되어 있는 LSTM을 적용하였다. FEMS에 적용되는 다양한 기능 중 에너지 소비 예측은 에너지 소비 현황 모니터링과 더불어 공장의 에너지 공급량과 비용을 합리적으로 설계하기 위한 중요한 첫 단계이다. 본 연구는 식품공장의 에너지관리시스템 개발에 앞서 최적의 예측 모델 도출을 위한 연구의 일환으로, 하이퍼파라미터 및 변수에 따른 예측 성능을 비교하였다. 대부분의 머신러닝 기반의 예측과 관련된 선행연구에서는 M&V Guideline에서 제시하는 모델의 평가지표인 MBE(Mean Bias Error), MAE(Mean Absolute Error), CvRMSE, R^2 등을 통해 모델의 신뢰성 검증은 하고 있다. 본 연구에서는 CvRMSE 및 R^2 지표를 통하여 하이퍼파라미터와 변수의 최적 조합을 도출하는 일련의 과정을 다룬다. 각 조합에 대해 예측 테스트를 10회씩 시행하여 최적의 조합을 도출하고, 해당 조합을 적용한 모델을 통해 예측값과 실측값의 비교를 통해 평균 오차를 및 예측 정확도를 확인하였다.

2. 이론적 배경

2.1 Factory Energy Management (FEMS)

FEMS는 실시간으로 공장의 에너지 사용을 모니터링, 분석 및 제어하며 에너지를 효율화하는 시스템이다. 공장에너지관리시스템의 구성요소

는 크게 하드웨어 측면, 소프트웨어 측면, 그리고 플랫폼 기술로 구분할 수 있다. 하드웨어 측면으로는 SCADA* 및 DCS*, 데이터 수집 및 저장 장치, 계측기, 네트워크 및 IT 인프라 등이 포함된다. 소프트웨어 측면은 공장에너지관리시스템에 포함되는 다양한 기능들이 포함된다. FEMS의 기능에는 에너지 및 생산 데이터의 측정 및 수집, 수집된 에너지 및 생산 데이터의 분석, EMIS*-MES* 연계 인터페이스를 통한 에너지 및 생산 정보의 가시화, 에너지 효율화를 위한 관리 및 제어가 있다. 분석 기능에는 에너지 소비량의 실시간 모니터링, 예측 등이 포함되며, 관리 및 제어 기능에는 설비 이상 진단 및 장애 대응, 전력피크 관리, 효율적인 운전 가이드 제공 등이 포함된다.

2.2 Machine Learning (ML)

머신러닝은 컴퓨터가 입력된 데이터를 바탕으로 스스로 학습해 의사결정하도록 하는 것으로, 입력 변수와 출력변수간의 관계를 찾아내어 함수를 만드는 것을 의미한다. 즉, 데이터에서 법칙성을 추출하는 통계적 방법의 하나로, 학습 데이터에 레이블이 있는 경우인 지도학습(Supervised Learning)과, 레이블이 없는 경우인 비지도학습(Unsupervised Learning)으로 구분할 수 있다. 지도학습에는 예측(Prediction) 모델과 분류(Classification) 모델이 있고, 비지도학습에는 군집화(Clustering) 모델이 있다. 지도학습에 해당하는 예측 모델의 대표적인 예에는 MLP, SVR(Support Vector Regression), RNN, LSTM, Decision Trees 등이 있다. 분류 모델의 대표적인 예에는 KNN(K-Nearest Neighbor), SVM, Random Forest 등이 있으며, 군집화 모델의 대표적인 예에는 K-Means Clustering, Mean-Shift Clustering, DBSCAN(Density-Based Spatial Clustering of Applications with Noise), GMM(Gaussian Mixture Model) 등이 있다.

머신러닝은 확보 가능한 데이터를 활용해 모델을 훈련시킬 수 있다는 점에서 큰 강점을 가지며, 기존의 방식들에 비해 보다 진보된 방식으로 건물을 최적 운영함에 매우 효율적이다.

본 연구에서는 식품공장의 에너지 소비 효율

화를 위해 전력 사용량 예측에 대해 고찰하고자 하며, 이에 지도학습의 예측 모델에 해당하며 시계열 예측에 가장 보편적으로 활용되고 있는 LSTM 알고리즘을 적용하였다.

2.3 Recurrent Neural Network (RNN)

RNN은 순차적인 데이터를 처리함에 특화된 신경망 구조로 이전 시점의 출력(h)을 현재 시점의 입력(x)으로 사용하면서 내부적으로 순환 구조를 가지고 있으며, 데이터가 순환되는 한 단계를 의미하는 타임 스텝(t) 마다 순환 뉴런을 구성하여 타임 스텝별 입력(x_t)과 출력(h_t)을 갖는다. t 시점에서 입력과 이전 시점의 출력(h_{t-1})을 받아 선형 변환 후 활성화함수 $\tanh$ 을 통과하고, 다음 시점 방향과 출력방향으로 값을 출력한다. 시계열 데이터 사용에 유리한 RNN은 gradient vanishing과 gradient exploding 문제가 발생하는 단점이 있다. Gradient vanishing이란 학습 과정에서 이전 정보와 그 정보를 사용하는 지점의 거리가 먼 경우 역전파(back propagation) 과정에서 기울기가 줄어들어 모델 학습력이 감소하는 현상을 의미한다. 반면 gradient exploding은 그와 반대로 역전파 과정에서 기울기가 증가하여 수치적인 안정성을 방해하고 가중치가 큰 업데이트를 수행함으로써 학습을 불안정하게 하는 현상을 의미한다. 이러한 gradient vanishing 및 exploding은 RNN에서 장기적인 의존성 학습을 방해하는 요소로 작용한다. Fig. 1은 RNN의 구조를 나타낸 것이다.




Fig. 1. Structure of RNN.

2.4 Long Short Term Memory (LSTM)

LSTM은 RNN과 마찬가지로 순차적인 데이터를 처리하는 데 사용되는 순환신경망 구조를 가지며, 특히 시계열 데이터 학습에 높은 성능을 발휘하는 알고리즘이다. LSTM은 RNN의 변형된 구조로, 정보의 흐름을 조절하는 gate mechanism과 장기적인 의존성을 유지하며 업데이트하는 LSTM 전용 기억 메커니즘인 cell state, 즉 memory cell과 LSTM의 출력인 hidden state가 추가되어 RNN에서 발생하는 gradient vanishing 및 exploding 문제를 완화한다. Gate mechanism은 불필요한 정보를 삭제하는 forget gate, 현재의 정보를 얼마나 기억할지 결정하는 input gate, 적절한 정보를 출력하여 장기 의존성을 유지하며 모델 성능을 향상시키는 output gate의 세 가지로 구성되어 각각의 가중치를 두고 학습을 한다. 즉, 가중치를 상수로 반복 곱하는 것이 아니라 control gate를 통해 상황에 맞게 값을 조절함으로써 문제를 해결한다. Forget gate(f_t), input gate(i_t), output gate(o_t)를 수식으로 나타내면 다음과 같으며((1)-(5), Fig. 2는 LSTM의 구조를 나타낸 것이다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1)$$

여기서 f_t 는 현재 시점의 forget gate의 출력,

σ 는 시그모이드 함수, W_f 는 forget gate의 가중치 행렬, h_{t-1} 은 이전 시점의 hidden state, x_t 는 현재 시점의 입력, $[h_{t-1}, x_t]$ 는 h_{t-1} 과 x_t 를 연결한 벡터, b_f 는 forget gate에 대한 편향을 나타낸다.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2)$$

여기서 i_t 는 현재 시점의 input gate의 출력, W_i 는 input gate의 가중치 행렬, b_i 는 input gate에 대한 편향을 나타낸다.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (3)$$

여기서 o_t 는 현재 시점의 output gate의 출력, W_o 는 output gate에 대한 가중치 행렬, b_o 는 output gate에 대한 편향을 나타낸다.

또한 cell state(C_t)와 hidden state(h_t)를 수식으로 나타내면 다음과 같다.

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (4)$$

여기서 C_t 는 현재 시점의 cell state, C_{t-1} 은 이전 시점의 cell state, $\tilde{C}_t$ 는 현재 시점의 새로운 정보(입력에 대한 후보값), $\odot$ 는 요소별 곱셈을 나타낸다.

$$h_t = o_t \odot \tanh(C_t) \quad (5)$$

여기서 h_t 는 현재 시점의 hidden state, $\tanh$ 는 하이퍼볼릭 탄젠트 함수를 나타낸다.




Fig. 2. Structure of LSTM.

3. LSTM 예측 모델 개발 및 평가

본 연구는 LSTM 기반의 식품공장 에너지 소비 예측 모델의 최적화를 목표로 한다. 연구절차는 크게 (1)대상 식품 공장의 데이터 확보, (2)상관관계 분석을 통한 활용 데이터 선정, (3)에너지 소비 예측 모델 구현, (4)예측 모델의 예측 정확도 평가의 4단계로 구분할 수 있다. Fig. 3은 연구절차를 요약한 것으로, 본 연구에서는 데이터 확보, 상관관계 분석, 에너지 소비 예측 모델 구현 및 예측 정확도 평가의 순으로 연구를 수행하였다.




Fig. 3. Research process.

3.1 데이터 확보

첫 번째 단계에서 대상 식품공장의 데이터를 확보하였다. 연구 대상 식품공장은 육가공 제품, 냉동식품 및 훈제제품을 제조하는 국내 중소기업의 업체로, 공정별 계측기가 구비되어 있지 않은 상태였으며 에너지 관리가 체계적으로 이루어지고 있지 않은 상태였다. 이에 연구에 앞서 생산 및 소비 데이터의 수집을 위해 다양한 계측 인프라를 구축하고 통신모듈 및 PLC를 연계하였으며, 상용 HMI 툴인 CIMON을 이용해 데이터 모니터링 및 수집이 가능하도록 과정이 필요하였다. 대상 식품공장의 전력 사용량 예측을 위해 2018년 1월 1일부터 2020년 12월 31일까지의 일 단위 데이터가 활용되었다. 활용된 데이터는 제품 종류별 생산량, 운영스케줄(투입시간 및 투입인원), 외기온도 데이터, 외기습도 데이터, 전 일의 전력 사용량 데이터가 포함된다. 대상 식품공장은 생산하는 제품의 종류에 따라 1공장 및 2공장으로 분류할 수 있으며, 제품 생산량, 운영스케줄 데이터는 대상 식품 공장의 생산일보 내용을 공장별로 분리하여 데이터베이스화 작업을 거쳐 활용하였다. 외기온도 및 외기습도 데이터는 기상청에서 제공하고 있는 대상 식품 공장이 위치한 지역의 데이터를 사용하였으며, 전력 사용량

데이터는 한국전력공사에서 제공하는 한전 파워플래너 서비스를 통해 확보하였다.

3.2 상관관계 분석

두 번째 단계에서는 확보한 데이터에 대해 전력 에너지 사용량과의 상관관계를 분석하였다. 각 변수별 전력 사용량과의 상관관계는 피어슨 상관계수(Pearson Correlation Coefficient)로 확인하였다. 상관계수에 대한 해석은 정해진 기준이 없어 데이터 특성, 샘플의 대표성에 따라 연구자의 해석방법이 달라질 수 있다. Rea & Parker[11]는 상관계수가 절댓값을 기준으로 0.0 ~ 0.1인 경우 ‘거의 관계가 없음’, 0.1 ~ 0.2인 경우 ‘약한 상관관계’, 0.2 ~ 0.4인 경우 ‘보통의 상관관계’, 0.4 ~ 0.6인 경우 ‘비교적 강한 상관관계’, 0.6 ~ 0.8인 경우 ‘강한 상관관계’, 0.8 ~ 1.0인 경우 ‘매우 강한 상관관계’를 의미한다고 해석하고 있다. 이에 상관관계가 거의 없다고 볼 수 있는 0.0 ~ 0.1 사이의 상관계수를 갖는 데이터는 예측 모델에서 제외하고자 하였다. 분석 결과, 모든 변수가 당일의 전력 사용량과 0.1 이상의 상관계수를 갖는 것을 확인하여, 변수 제외 없이 제품 생산량, 운영스케줄, 외기온도 및 외기습도, 전 일

전력 사용량의 모든 데이터가 활용되었다. 전체 제품 생산량 및 2공장 제품 생산량(0.70), 전체 투입시간 및 1공장 투입시간(0.69), 전체 투입인원 수 및 1공장 투입인원 수(0.67), 2공장 투입시간(0.64), 전 일 전력 사용량(0.62), 1공장 제품

생산량(0.58), 2공장 투입인원 수(0.57), 외기온도(0.29), 외기습도(0.12) 순으로 당일 전력 사용량과 상관관계가 높은 것을 확인하였다. Table 1에 활용된 데이터를 정리하였으며, Fig. 4는 각 변수의 전력 사용량에 대한 상관계수를 나타낸다.

Table 1. Data for energy consumption prediction.

Category		Data Type	Notation
a	Electricity Consumption	Electricity consumption of the day	ELECTRICITY
		Electricity consumption of the previous day	ELECTRICITY_B
b	Product production	Total product production	PRODUCT_T
		Product production in factory 1	PRODUCT_1
		Product production in factory 2	PRODUCT_2
c	Input Time	Total input time	TIME_T
		Input time in factory 1	TIME_1
		Input time in factory 2	TIME_2
d	Input Workforce	Total input workforce	PEOPLE_T
		Input workforce in factory 1	PEOPLE_1
		Input workforce in factory 2	PEOPLE_2
e	External Environment	Outdoor temperature	TEMPERATURE
		Outdoor humidity	HUMIDITY




Fig. 4. Results of Correlation Analysis.

3.3 에너지 소비 예측 모델 구현

예측 모델은 Python 3.9.7, Tensorflow 2.3.0, Keras 2.4.3, Sklearn 1.0.2, pandas 1.4.1, Numpy 1.19.5, Matplotlib 3.5.1 환경에서 구현하였다. 데이터의 정규화를 위해 sklearn의 MinMaxScaler를 활용하였고, epoch는 keras의 early stopping callback 함수를 사용해 과적합을 방지하였으며, loss function으로는 Mean Squared Error(MSE)를 사용하였다. 또한 데이터는 train set 90%, test set 10%로 분리하여 적용하였다.

세 번째 단계에서는 에너지 소비 예측 모델을

구현하고, 하이퍼파라미터 및 변수 조합에 따른 결정계수 R^2 및 CvRMSE 값을 비교하였다.

R^2 는 분산 기반의 예측 성능 평가지표로 주로 회귀 분석 및 통계적 분석에 활용되며, 값이 0에 가까울수록 상관관계가 적고 1에 가까울수록 상관관계가 높음을 의미한다. R^2 는 다음의 수식으로 나타낼 수 있다.

$$R^2 = \frac{ESS}{TSS} = \left(1 - \frac{RSS}{TSS}\right) = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (6)$$

여기서 ESS는 Explained Sum of Squares의 약어로 Y의 각 예측값과 평균값 간 차이의 제곱합을 의미하며, 목표값 Y의 변동량 중에서 모델이 설명하지 못하는 정도를 나타낸다. TSS는 Total Sum of Squares의 약어로 Y의 각 실제값과 평균값 간 차이의 제곱합을 의미하며, 목표값 Y의 변동량을 나타낸다. RSS는 Residual Sum of Squares의 약어로 Y의 각 실제값과 그 값의 예측값 간 차이의 제곱합을 의미하며, 목표값 Y

의 변동량 중에서 모델이 설명하지 못하는 정도를 나타낸다. 또한 y_i 는 실측값, $\bar{y}_i$ 는 y 의 평균값, $\hat{y}_i$ 는 모델을 통한 예측값을 의미한다.

ASHRAE(American Society of Heating, Refrigerating and Air-Conditioning Engineers) Guideline[12]에서 0.80, 즉 80% 이상을 적정 기준으로 제시하고 있다. 이에 R^2 0.80 이상을 예측 모델 성능의 목표값으로 설정하였다.

CvRMSE는 분산 정도를 오차 분석으로 실측값과 예측값의 오차를 파악하는 것으로, 결과값은 오차율(%)로 표현된다. RMSE를 백분율화 시킨 값이 CvRMSE로, RMSE 및 CvRMSE는 다음의 수식으로 나타낼 수 있다.

$$RMSE = \sqrt{\frac{\sum(\hat{y}_i - y_i)^2}{N}} \quad (7)$$

$$CvRMSE = \frac{RMSE}{\mu} \times 100 = \frac{\sqrt{\frac{\sum(\hat{y}_i - y_i)^2}{N}}}{\mu} \times 100(\%)$$

여기서 N 은 실측 데이터 수, μ 는 실측 데이터의 평균값, y_i 는 실측값, $\bar{y}_i$ 는 y 의 평균값, $\hat{y}_i$ 는 모델을 통한 예측값을 의미한다.

ASHRAE Guideline에서 월 단위(monthly) 데이터를 사용하는 경우 10% 이하, 시간 단위(hourly) 데이터를 사용하는 경우 30% 이하로 기준을 제시하고 있다. 본 연구에서는 일 단위 데이터를 사용하였으므로 ASHRAE에서 제시하는 월 단위 기준과 시간 단위 기준의 중간값인 20%를 목표값으로 설정하였다. Table 2에 R^2 및 CvRMSE에 대한 ASHRAE Guideline 기준 및 목표값을 정리하였다.

Table 2. Criteria of ASHRAE Guideline and target value.

Category	Unit	R^2	CvRMSE
ASHRAE Guideline	Monthly	0.80 (80 %)	10 %
	Hourly		30 %
Target Value	Daily		20 %

3.3.1 하이퍼파라미터 조합에 따른 예측 성능 비교

하이퍼파라미터 조합에 따른 예측 성능을 비교하기 위해 epoch, batch size, optimizer, 그리고 window size를 조정하였다. 기준 조합으로는 기본 설정값(default), 즉 epoch는 10, batch size는 32, optimizer는 Adam으로 설정하였으며, window size는 문제 또는 상황에 따라 기본값이 달라지므로 보편적으로 사용되는 값인 60으로 설정하였다. 기준 조합에서 각각의 하이퍼파라미터를 조정하며 각 조합별로 10번씩의 예측 테스트를 시행하여 R^2 와 CvRMSE의 평균값으로 모델의 타당성(신뢰도)를 확인하였다.

(1) Epoch

첫 번째로, batch size는 default인 32, optimizer는 default인 Adam, 그리고 window size는 60으로 고정한 상태에서 epoch를 10, 40, 70, 100으로 설정할 때의 R^2 와 CvRMSE 값의 변화를 확인하였다(Fig. 5). 테스트 결과, epoch 값이 증가할수록 R^2 가 증가하고 CvRMSE 값이 감소하는 경향을 확인할 수 있었으며, epoch가 100인 경우 모델 타당성이 가장 우수함을 확인하였다 (avg. R^2 81.08%, avg.CvRMSE 17.63%).




Fig. 5. R^2 and CvRMSE according to epoch.

(2) Batch Size

두 번째로, epoch는 선행 테스트 결과 모델 타당성 측면에서 가장 우수했던 100으로, optimizer은

default인 Adam, 그리고 window size는 60으로 고정된 상태에서 batch size를 16, 32, 64, 128로 설정할 때의 R^2 와 CvRMSE 값의 변화를 확인하였다 (Fig. 6). 테스트 결과, batch size 값이 16에서 32가 될 때에는 모델 타당성이 높아졌으나, 32에서 64, 128이 될 때에는 모델 타당성이 낮아지는 경향을 확인할 수 있었다. 4가지 케이스 중 batch size가 32인 경우 모델 타당성이 가장 우수하였다 (avg. R^2 81.08%, avg.CvRMSE 17.63%).

(3) Optimizer

세 번째로, epoch와 batch size는 선행 테스트 결과 모델 타당성 측면에서 가장 우수했던 설정값, 즉 각각 100, 32로, 그리고 window size는 60으로 고정된 상태에서 optimizer를 Adam, Nadam, RMSprop, SGD로 설정할 때의 R^2 와 CvRMSE 값의 변화를 확인하였다(Fig. 7). 테스트 결과, optimizer가 Adam, Nadam, RMSprop, SGD인 순으로 모델 타당성이 확보됨을 확인하였다. SGD의 경우에는 모델 타당성이 매우 부족하였으며, Adam으로 설정하였을 때 모델 타당성이 가장 우수함을 확인하였다 (avg. R^2 81.08%, avg.CvRMSE 17.63%).




Fig. 6. R^2 and CvRMSE according to batch size.




Fig. 7. R^2 and CvRMSE according to optimizer.

(4) Window Size

네 번째로, epoch, batch size, optimizer는 선행 테스트 결과 모델 타당성 측면에서 가장 우수했던 설정값인 100, 32, Adam으로 고정된 상태에서 window size를 5, 20, 60, 100으로 설정할 때의 R^2 와 CvRMSE 값의 변화를 확인하였다(Fig. 8). 테스트 결과, window size 값이 증가할수록 R^2 값이 증가하고 CvRMSE 값이 감소하는 경향을 확인하였으며, window size가 100인 경우 모델 타당성이 가장 우수함을 확인하였다 (avg. R^2 81.22%, avg.CvRMSE 17.62%).




Fig. 8. R^2 and CvRMSE according to window size.

Table 3. R^2 and CvRMSE according to combination of variables.

Case	Variables	R^2	CvRMSE	Case	Variables	R^2	CvRMSE
1.	a, b, c, d, e	81.22 %	17.62 %	17.	b, c, d, e	78.61 %	18.79 %
2.	a, b, c, d	76.79 %	19.51 %	18.	b, c, d	77.89 %	19.04 %
3.	a, b, c, e	76.53 %	15.91 %	19.	b, c, e	78.66 %	18.75 %
4.	a, b, d, e	75.34 %	20.16 %	20.	b, d, e	77.84 %	19.14 %
5.	a, c, d, e	76.22 %	19.78 %	21.	b, c	77.57 %	19.21 %
6.	a, b, c	76.13 %	19.87 %	22.	b, d	73.28 %	20.96 %
7.	a, b, d	78.91 %	18.65 %	23.	b, e	75.81 %	19.98 %
8.	a, b, e	77.06 %	19.45 %	24.	b	74.62 %	20.28 %
9.	a, c, d	77.46 %	19.30 %	25.	c, d, e	77.87 %	19.11 %
10.	a, c, e	74.45 %	20.43 %	26.	c, d	74.23 %	20.65 %
11.	a, d, e	72.28 %	21.39 %	27.	c, e	76.86 %	19.56 %
12.	a, b	76.99 %	19.46 %	28.	c	76.91 %	19.49 %
13.	a, c	77.97 %	19.09 %	29.	d, e	73.47 %	20.93 %
14.	a, d	75.96 %	19.92 %	30.	d	75.38 %	20.19 %
15.	a, e	77.39 %	19.31 %	31.	e	78.43 %	18.88 %
16.	a	79.70 %	18.33 %				

3.3.2 변수 조합에 따른 예측 성능 비교

변수 조합 테스트에서는 하이퍼파라미터 조합 테스트에서 가장 높은 예측 타당성을 보인 조합(epoch 100, batch size 32, optimizer Adam, window size 100)을 기준으로 하였다.

전력 사용량 예측을 위해 확보된 데이터는 전 일 전력 사용량(a), 제품 생산량(전체 제품 생산량, 1공장 제품 생산량, 2공장 제품 생산량)(b), 인력 투입시간(전체 인력 투입시간, 1공장 인력 투입시간, 2공장 인력 투입시간)(c), 투입인원 수(전체 투입인원 수, 1공장 투입인원 수, 2공장 투입인원 수)(d), 외기온도 및 외기습도(e)이다. a, b, c, d, e 변수로 31가지 조합에 대해 각각 10씩의 예측 테스트를 시행하여 R^2 와 CvRMSE의 평균값으로 모델의 타당성(신뢰도)를 확인하였다. 다음의 Table 3은 31가지 변수 조합 및 변수 조합 별 평균 R^2 및 CvRMSE 값을 정리한 표이다.

테스트 결과, 모든 변수를 사용한 case 1의 모델 타당성이 가장 우수하였으며(avg. R^2 81.22%, avg.CvRMSE 17.62%), 전력 사용량(a), 투입인원 수(d), 외부환경(e) 데이터를 사용한 case 11의 모델 타당성이 가장 부족함을 확인하였다(avg. R^2 72.28%, avg.CvRMSE 21.39%). 반면 두 번째로 모델 타당성 측면에서 우수한 결과를 보이는 케이스는 전력 사용량 데이터(a)만을 사용한 case 16으로 확인하였다(avg. R^2 79.70%, avg.CvRMSE 18.33 %). Fig. 9에 각 변수 조합 별 결과를 정리하였다.

Date	Measured Value(kWh)	Predicted Value(kWh)	Error Rate	Date	Measured Value(kWh)	Predicted Value(kWh)	Error Rate
2020-12-01	10890.3	12796.7	18 %	2020-12-16	11355.3	13841.6	22 %
2020-12-02	11302.8	12519.6	11 %	2020-12-17	11482.5	12880.9	12 %
2020-12-03	11840.7	12764.2	8 %	2020-12-18	11137.9	10218.7	8 %
2020-12-04	11208.4	12658.7	13 %	2020-12-21	9740.27	9945.17	2 %
2020-12-07	9953.68	12695.9	28 %	2020-12-22	11696.4	11596	1 %
2020-12-08	11317.8	12717.8	12 %	2020-12-23	11630.1	12186.2	5 %
2020-12-09	11500.8	12120.2	5 %	2020-12-24	11798.4	12466.9	6 %
2020-12-10	11738.8	13281.6	13 %	2020-12-25	5864.58	4513.56	23 %
2020-12-11	11194.5	12958.6	16 %	2020-12-28	9984.05	12206.4	22 %
2020-12-14	9621.43	13100.2	36 %	2020-12-29	11929.4	12237	3 %
2020-12-15	11484.1	13871.8	21 %	2020-12-30	11838	13753.9	16 %
※ 주말(토/일)은 제외 : 12/5, 12/6, 12/12, 12/13, 12/19, 12/20, 12/26, 12/27							
Average of Error Rate						18.61 %	
Accuracy of Prediction						81.39 %	




Fig. 11. Comparison of measured and predicted values.

4. 결론 및 고찰

본 연구는 식품공장 FEMS에의 적용을 위해 LSTM 기반 에너지 사용량 예측을 위해 최적의 하이퍼파라미터 및 변수 조합을 도출함에 목적이 있다. 각 조합별로 10번씩의 예측 테스트를 시행하였으며 예측 모델의 타당성(신뢰도)을 R^2 및 CvRMSE의 평균값으로서 확인하였다.

하이퍼파라미터 조합 테스트 대상에는 epoch, batch size, optimizer, window size가 포함되며, 기준 조합으로 epoch는 10, batch size는 32, optimizer는 Adam, window size는 60으로 설정되었다. Epoch, batch size, optimizer, window size 순

으로 테스트를 진행하였으며, 모델 타당성이 가장 높았던 선행 테스트 대상의 하이퍼파라미터의 대안을 후속 테스트에 적용하였다. 하이퍼파라미터 조합에 따른 예측 성능 비교에서 확인한 주요 결과를 정리하면 다음과 같다.

1. Epoch의 값이 증가할수록 예측 타당성, 즉 R^2 가 증가하고 CvRMSE 값이 감소하는 경향을 확인하였다. 또한 epoch 10, 40, 70, 100 중 100인 경우에만 avg. R^2 81.08%, avg.CvRMSE 17.63%로 목표값(R^2 80% 이상, CvRMSE 20% 이하)에 부합하였다.

2. Batch size의 경우, 16에서 32가 될 때에는 모델 타당성이 높아졌으나, 32에서 64, 128이 될 때에는 모델 타당성이 점차 낮아지는 경향을 확인하였다. 또한 batch size 16, 32, 64, 128 중 16일 때 avg. R^2 80.14%, avg.CvRMSE 18.06%, 그리고

32일 때 avg.R^2 81.08%, avg.CvRMSE 17.63%로 목표값에 부합하였다.

3. Optimizer의 경우, Adam, Nadam, RMSprop, SGD 순으로 모델 타당성이 우수하였으며, SGD 일 경우에는 모델 타당성이 매우 부족하였다. 또한 Adam일 경우에만 avg.R^2 81.08%, avg.CvRMSE 17.63%로 목표값에 부합하였다.

4. Window size의 경우, 값이 커질수록 모델 타당성이 확보되는 것을 확인하였으며, window size 5, 20, 60, 100 중 60인 경우 avg.R^2 81.08%, avg.CvRMSE 17.63%, 그리고 100인 경우 avg.R^2 81.22%, avg.CvRMSE 17.62%로 목표값에 부합함을 확인하였다.

5. 테스트 결과, epoch 100, batch size 32, optimizer Adam, window size 100의 조합에서 avg.R^2 81.22%, avg.CvRMSE 17.62%로 모델의 예측 타당성이 가장 우수하였다.

머신러닝 기반의 에너지 소비 예측은 사용자가 설정해주는 하이퍼파라미터에 따라 예측 성능이 크게 달라지므로 적절한 설정 조합을 찾는 것이 중요하다. 이와 같은 연구는 하이퍼파라미터 테스트 집합 범위의 조정을 위한 자료로 활용될 수 있으며 최적화 방향성 설정에 도움이 될 것으로 기대한다.

반면 변수 조합 테스트 대상에는 전력 사용량, 제품 생산량, 인력 투입시간, 투입인원 수, 외기 온도 및 외기습도가 포함되며 총 31가지의 변수 조합에 대해 테스트하였다. 변수 조합 테스트에 있어서는 앞선 하이퍼파라미터 테스트 결과 모델 타당성이 가장 우수했던 조합(epoch 100, batch size 32, optimizer Adam, window size 100)을 적용하였다. 변수 조합에 따른 예측 성능 비교에서 확인한 주요 결과를 정리하면 다음과 같다.

1. 모든 변수(a, b, c, d, e)를 사용한 case 1의 모델 타당성이 avg.R^2 81.22%, avg.CvRMSE 17.62%로 가장 우수하였다.

2. 변수 a만을 사용한 case 16가 avg.R^2 79.70%, avg.CvRMSE 18.33%로 두 번째로 모델 타당성이 우수하였다.

에너지 사용 예측에 있어 활용 변수의 최소화는 계측 인프라 구축의 단순화를 의미하며, 이러한 계측 인프라 종류의 단순화는 제반 비용을 줄임으로써 사업자의 FEMS 적용 부담을 줄이고 접근성을 높일 수 있다. 이에 case 16은 매우 의미 있는 결과이며, 보다 높은 예측 성능을 확보하여 대안으로 충분히 적용 가능할 것이다.

마지막으로 최적 하이퍼파라미터 및 변수 조합을 적용한 예측 모델을 통해 한 달치에 대해 예측값을 도출하고 실측값과 비교를 통해 평균 오차율 및 예측 정확도를 평가하였다. 그 결과 평균 오차율은 13.98%, 예측 정확도는 86.02%로 확인되었다.

추후 추가적인 모델 고도화 작업을 통해 예측 모델의 타당성과 예측 정확도를 추가 확보 가능할 것으로 기대한다. 본 연구에서는 4가지 하이퍼파라미터에 대해 기본 설정값을 기준으로 각 4가지 대안에 대해 테스트하였으나, epoch, batch size, optimizer, window size 외의 하이퍼파라미터에 대해서도 테스트가 필요하며 대안의 수를 늘려 추가적인 테스트를 진행할 필요가 있다. 또한 본 연구에서는 시계열 예측에 강점을 가지는 LSTM 알고리즘 기반의 전력 사용량 예측을 고찰하였으나, 환경 및 에너지 측면에서 보편적으로 사용되고 있는 MLP 및 SVR 등의 다양한 알고리즘을 적용하여 대상 식품공장에 보다 적합한 알고리즘 도출이 가능할 것이다.

감사의 글

이 논문은 산업통상자원부(MOTIE)와 한국에너지기술평가원(KETEP)의 지원을 받아 수행한 연구입니다. (No. 20202020800290)

NOMENCLATURE

BAU : 'Business As Usual'의 약어로 온실가스 감축을 위한 인위적 조치를 하지 않을 경우 예상되는 온실가스 배출 총량을 의미한다.

TOE : 'Tone of Oil Equivalent'의 약어로 국제

에너지기구(International Energy Agency, IEA)에서 정한 석유환산톤 단위를 의미한다.

SCADA : ‘Supervisory Control and Data Acquisition’의 약어로 감시 제어 및 데이터 취득 시스템을 의미한다. 대체로 생산 공정을 감시하고 제어함에 사용되는 대규모 소프트웨어 패키지, 또는 산업체에서 플랜트의 상태를 감시하고 제어함에 사용되는 시스템을 의미한다.

DCS : ‘Distributed Control Systems’의 약어로, 에너지기구(International Energy Agency, IEA)에서 정한 석유환산톤 단위를 의미한다.

EMIS : ‘Energy Management Information System’의 약어로, 건축물이나 제조 현장에서 에너지 사용을 실시간 모니터링하며 에너지 절감 방안을 도출하는 시스템을 의미한다.

MES : ‘Manufacturing Execution System’의 약어로, 생산 현장에서 품질 관리, 작업 일정 관리, 작업 실적 관리 등 제반 활동의 지원을 위한 관리 시스템을 의미한다.

References

- [1] 김철우, 김진, 김석민, 황현태, “제조 산업 에너지 절감을 위한 공장에너지관리시스템(FEMS) 기술 동향 및 적용사례”, 대한설비공학회 설비저널, 44(1), pp.22~27(2015).
- [2] 산업통상자원부, “2020년 에너지총조사 결과”, pp.1~200(2022).
- [3] 산업통상자원부, “2013년 EMS 도입현황 실태조사 보고서”, 1~192(2014).
- [4] 여인규, “온실가스·에너지 규제강화, FEMS 주목”, 냉난방공조 신재생 녹색건축 전문저널 칸, <http://www.kharn.kr/news/article.html?no=13643>(2020).
- [5] Comesaña, M.M.; Febrero-Garrido, L.; Troncoso-Pastoriza, F.; Martínez-Torres, J. “Prediction of building’s thermal performance using LSTM and MLP neural networks”, *Energies*, 10(21), 7439(2020).
- [6] Lee, C.; Jung, D.E.; Lee, D.; Kim, K.H.; Do, S.L., “Prediction performance analysis of artificial neural network model by input variable combination for residential heating loads”, *Energies*, 14(3), 756(2021).
- [7] Junlong, Q., 신지웅, 고정림, 신승권, “SSIM 및 VLSW 알고리즘을 활용한 결측치가 포함된 건물에너지관리시스템 데이터로부터의 에너지 소비량 예측에 관한 연구”, 대한전기학회 전기학회 논문지, 70(10), pp.1,540~1,547(2021)
- [8] 양윤경, 박진철, “인공지능 기반 헬스케어 건물의 에너지 효율 예측 모델”, 대한설비공학회 설비공학논문집, 34(7), pp.336~344(2022).
- [9] 최종석, 신용태, “매장 에너지 절감을 위한 LSTM 기반의 전력부하 예측 시스템 설계”, 한국정보전자통신기술학회 논문지, 14(4), pp.307~313(2021).
- [10] 김동주, 여채은, 구재희, “공장에너지관리시스템(FEMS) 적용을 위한 식품 공정 에너지 소비 패턴 분석”, 열환경공학회지, 16(2), pp.1~8(2021).
- [11] Rea, L.; Parker, A., “Designing and Conducting Survey Research: A Comprehensive Guide (3rd ed.)”, John Wiley & Sons, Inc., Jossey-Bass: Hoboken, NJ, USA, pp.1~352(2005).
- [12] ASHRAE(American Society of Heating, Refrigerating and Air Conditioning Engineers), ASHRAE Guideline 14: Measurement of Energy and Demand Savings; ASHRAE: Atlanta, GA, USA, pp.4~165(2022).